第6回：グループで集計する - GROUP BY

「〇〇ごと」の合計や件数を計算できるようになる

● 本日のゴール

✅ 「〇〇ごと」の合計や件数を計算できるようになる

● 座学パート

1. GROUP BYとは？

データをグループに分けて、各グループごとに集計する機能。

- 「顧客ごとの購入回数」
- 「商品ごとの売上数量」
- 「日付ごとの売上件数」

2. 基本構文

```
SELECT
      グループ化する列,
      集計関数
FROM テーブル
GROUP BY グループ化する列;
```

3. 重要なルール

- SELECTに書く列は、GROUP BYに含まれるか、集計関数である必要がある
- GROUP BYと集計関数（COUNT、SUM、AVGなど）はセットで使う
- 複数の列でグループ化も可能

4. イメージで理解

元データ：

```
customer_id | quantity
C001        | 5
C001        | 10
C002        | 2
C002        | 1
```

GROUP BY customer_id の結果：

```
customer_id | SUM(quantity)
C001        | 15
C002        | 3
```

● 演習パート

演習1：顧客IDごとの購入回数を数える

```
SELECT
    customer_id,
    COUNT(*) AS 購入回数
FROM 'data/sales.csv'
GROUP BY customer_id;
```

結果を確認：

- 誰が一番多く購入している？

並び替えを追加

```
SELECT
    customer_id,
    COUNT(*) AS 購入回数
FROM 'data/sales.csv'
GROUP BY customer_id
ORDER BY 購入回数 DESC;
```

演習2：商品IDごとの売上数量合計

```
SELECT
    product_id,
    SUM(quantity) AS 総売上数量
FROM 'data/sales.csv'
GROUP BY product_id;
```

どの商品が一番売れている？

演習3：【応用】売上数量TOP3の商品

```sql
SELECT
    product_id AS 商品ID,
    SUM(quantity) AS 総売上数量
FROM 'data/sales.csv'
GROUP BY product_id
ORDER BY 総売上数量 DESC
LIMIT 3;
```

これは複合技！

1. GROUP BYで商品ごとに集計
2. ORDER BYで多い順に並び替え
3. LIMITで上位3つだけ表示

応用練習

1. 複数の集計を同時に

```
SELECT
    customer_id AS 顧客ID,
    COUNT(*) AS 購入回数,
    SUM(quantity) AS 総購入数,
    AVG(quantity) AS 平均購入数
FROM 'data/sales.csv'
GROUP BY customer_id;
```

2. 条件付きGROUP BY

```sql
-- 5個以上購入したことがある顧客の統計
SELECT
    customer_id,
    COUNT(*) AS 大量購入回数,
    SUM(quantity) AS 総購入数
FROM 'data/sales.csv'
WHERE quantity >= 5
GROUP BY customer_id;
```

3. 日付でグループ化

```
-- 日付ごとの売上統計
SELECT
    order_date AS 売上日,
    COUNT(*) AS 取引件数,
    SUM(quantity) AS 販売数量
FROM 'data/sales.csv'
GROUP BY order_date
ORDER BY order_date;
```

実践的な使い方

ケース1：顧客分析レポート

```sql
-- 優良顧客の特定（購入回数3回以上）
SELECT
    customer_id AS 顧客ID,
    COUNT(*) AS 購入回数,
    SUM(quantity) AS 総購入数
FROM 'data/sales.csv'
GROUP BY customer_id
HAVING COUNT(*) >= 3
ORDER BY 総購入数 DESC;
```

ケース2：商品カテゴリ分析

```sql
-- カテゴリごとの商品統計
SELECT
    category AS カテゴリ,
    COUNT(*) AS 商品数,
    AVG(price) AS 平均価格,
    MAX(price) AS 最高価格
FROM 'data/products.csv'
GROUP BY category;
```

GROUP BYを理解する

ステップバイステップで確認

1. まず元データを確認

```
SELECT customer_id, quantity
FROM 'data/sales.csv'
ORDER BY customer_id;
```

2. GROUP BYで集計

```
SELECT
    customer_id,
    SUM(quantity) AS 合計
FROM 'data/sales.csv'
GROUP BY customer_id;
```

→ 元データと集計結果を並べて比較できる！

よくあるエラーと対処法

> ⚠️ **エラーになる例：**

```sql -- product_idがGROUP BYにない！ SELECT customer_id, product_id, -- これがエラーの原因 COUNT(*) FROM 'data/sales.csv' GROUP BY customer_id;
```

> 💡 **正しい例：**

```sql
SELECT customer_id, COUNT(*) AS 購入回数
FROM 'data/sales.csv'
GROUP BY customer_id;
```

GROUP BYの活用パターン

1. ランキング作成

```
-- 売れ筋商品ランキング
SELECT
    product_id,
    SUM(quantity) AS 売上数
FROM 'data/sales.csv'
GROUP BY product_id
ORDER BY 売上数 DESC;
```

2. 期間集計

```sql
-- 月ごとの集計（仮想的な例）
SELECT
    SUBSTR(order_date, 1, 7) AS 年月,
    COUNT(*) AS 件数
FROM 'data/sales.csv'
GROUP BY SUBSTR(order_date, 1, 7);
```

3. 複数列でのグループ化

```
-- 顧客×商品の組み合わせ
SELECT
    customer_id,
    product_id,
    SUM(quantity) AS 購入数
FROM 'data/sales.csv'
GROUP BY customer_id, product_id;
```

● 本日のまとめ

今日学んだこと：

- ✅ `GROUP BY` でデータをグループ化
- ✅ 各グループごとに集計関数を適用
- ✅ `HAVING` で集計結果をフィルタリング
- ✅ WHEREとHAVINGの使い分けを理解
- ✅ 複数列でのグループ化も可能

よく使うパターン

```sql
-- 基本形
SELECT
    グループ列,
    COUNT(*),
    SUM(数値列),
    AVG(数値列)
FROM テーブル
GROUP BY グループ列;

-- ランキング
SELECT
    グループ列,
    集計関数 AS 集計値
FROM テーブル
GROUP BY グループ列
ORDER BY 集計値 DESC
LIMIT 10;
```

次回予告

第7回では、INNER JOINを使って複数のテーブルを結合する方法を学びます。
IDだけでなく、商品名や顧客名を表示できるようになります！

● 追加演習問題

問題1：基本的なGROUP BY

以下のグループ化集計を実行：

```
-- 1. 商品IDごとの販売回数
-- あなたの答えをここに書いてください

-- 2. 日付ごとの売上件数と合計数量
-- あなたの答えをここに書いてください

-- 3. カテゴリごとの商品数と最高価格
-- あなたの答えをここに書いてください
```

問題2：複数の集計関数

GROUP BYと様々な集計関数の組み合わせ：

```
-- 顧客ごとの購買行動分析
SELECT
    customer_id,
    ___ AS 購入回数,
    ___ AS 総購入数,
    ___ AS 平均購入数,
    ___ AS 最大購入数,
    ___ AS 最小購入数
FROM 'data/sales.csv'
GROUP BY ___;
```

問題3：HAVING句の活用

集計結果に条件を付ける：

```
-- 1. 2回以上売れた商品のリスト
SELECT product_id, COUNT(*) as 販売回数
FROM 'data/sales.csv'
GROUP BY product_id
HAVING ___ >= ___;

-- 2. 合計購入数が15個以上の顧客
-- あなたの答えをここに書いてください

-- 3. 平均価格が3万円以上のカテゴリ
-- あなたの答えをここに書いてください
```

問題4：実務シナリオ

ビジネスで使えるグループ化集計：

```
-- 1. ABC分析（売れ筋商品の特定）
-- 商品ごとの売上数量を集計し、上位20%を特定
-- あなたの答えをここに書いてください
```

問題4（続き）

```
-- 2. 顧客セグメント分析
-- 購入金額帯別の顧客数（仮に単価1万円として）
SELECT
    CASE
        WHEN SUM(quantity) * 10000 < 50000 THEN 'ライト'
        WHEN SUM(quantity) * 10000 < 200000 THEN 'ミドル'
        ELSE 'ヘビー'
    END AS 顧客層,
    COUNT(*) AS 顧客数
FROM 'data/sales.csv'
GROUP BY 顧客層;
```

🎯 チャレンジ問題

```
-- 複数列でのGROUP BY：
-- 顧客×商品の組み合わせごとの購入パターン分析
-- （同じ顧客が同じ商品を何回、合計何個購入したか）
```

💡 実践問題：月次レポート作成

```
-- 以下のレポートを作成：
-- 1. 日別売上サマリー
--      - 各日の取引件数
--      - 各日のユニーク顧客数
--      - 各日の総販売数量

-- 2. 商品別パフォーマンス
--      - 各商品の販売回数
--      - 各商品の総販売数量
--      - 購入した顧客数（DISTINCT使用）
```

🔍 デバッグ練習

以下のクエリの問題点を修正：

```
-- エラー1：GROUP BYに含まれない列
SELECT customer_id, product_id, COUNT(*)
FROM 'data/sales.csv'
GROUP BY customer_id;

-- エラー2：集計関数なしのGROUP BY
SELECT customer_id
FROM 'data/sales.csv'
GROUP BY customer_id;

-- エラー3：HAVINGとWHEREの混同
SELECT customer_id, COUNT(*) as cnt
FROM 'data/sales.csv'
```

📊 応用：GROUP BYの組み合わせ

```sql
-- 1. サブクエリを使った分析（先取り）
-- 平均購入数量を上回る顧客のリスト
WITH avg_purchase AS (
    SELECT AVG(quantity) as avg_qty FROM 'data/sales.csv'
)
SELECT customer_id, AVG(quantity) as 顧客平均
FROM 'data/sales.csv'
GROUP BY customer_id
HAVING AVG(quantity) > (SELECT avg_qty FROM avg_purchase);
```

応用（続き）

```
-- 2. 複雑な集計
-- 顧客ごとの「最頻値商品」を見つける
-- ヒント：顧客ごと、商品ごとにカウントして、最大値を探す
```

🎮 総合演習：売上分析ダッシュボード

```
-- 経営者向けのダッシュボードに必要な数値を全て集計：
-- 1. 顧客別売上ランキングTOP3
-- 2. 商品別売上ランキングTOP3
-- 3. 日別売上推移（件数と数量）
-- 4. カテゴリ別の売上比率
-- それぞれ個別のクエリで作成してください
```

🏆 上級問題：クロス集計

```sql
-- 顧客×日付のクロス集計表を作成
-- （どの顧客がどの日に何個購入したか）
SELECT
    customer_id,
    SUM(CASE WHEN order_date = '2024-01-15' THEN quantity ELSE 0 END) AS "1月15日",
    SUM(CASE WHEN order_date = '2024-01-16' THEN quantity ELSE 0 END) AS "1月16日",
    SUM(CASE WHEN order_date = '2024-01-17' THEN quantity ELSE 0 END) AS "1月17日"
    -- 続きを書いてみましょう
FROM 'data/sales.csv'
GROUP BY customer_id;
```

FAQ

Q: WHEREとHAVINGの違いは？

A: WHERE = GROUP BY前の絞り込み、HAVING = GROUP BY後の絞り込み

Q: GROUP BYの列は必ずSELECTに書く？

A: 書かなくても動きますが、結果が分かりにくくなるので書くことを推奨。

Q: 集計結果が0の場合も表示したい

A: LEFT JOINなどを使う必要があります（第8回で学習）。